

HOCHSCHULE MÜNCHEN · FAKULTÄT MUC.DAI

BACHELORARBEIT · KOLLOQUIUM

Neuronale Operatoren verstehen

Simulation partieller Differentialgleichungen und Entwicklung
didaktischer Lerneinheiten für Studierende im Digital Engineering

Understanding Neural Operators

Simulation of PDEs and Development of Learning Nuggets for Digital Engineering Students

Miray Kurt

Studiengang Digital Engineering

Motivation & Ausgangslage

- Interesse daran, komplexe Inhalte verständlich und praxisnah aufzubereiten und digitale Lehr- und Lernkonzepte zu entwickeln
- Ausgangspunkt: PDEBench sowie das Thema neuronale Netze bzw. Operatoren
- Die Themenwahl entstand aus der Frage, warum gewisse Themen in der Bachelorarbeit vorausgesetzt, im Studium aber nicht vermittelt werden

Die Lücke liegt zwischen dem, was von Studierenden erwartet wird, und dem, was ihnen anwendungsnah vermittelt wird.

Fragestellung & Ziel

Wie lässt sich ein aufeinander aufbauender, praxisnaher Lernpfad konzipieren, der Studierenden einen verständlichen und strukturierten Zugang zu neuronalen Operatoren ermöglicht?

1

Docker & Containerisierung

Wird in vielen Abschlussarbeiten genutzt, taucht im Studienplan aber nicht auf

Technisches Fundament

2

Partielle Differentialgleichungen

Erscheinen nur implizit, etwa in der numerischen Strömungssimulation

Fachlicher Kern

3

Neuronale Operatoren


Werden meist rein theoretisch gestreift, kaum anwendungsnah

Verbindung und Anwendung

Didaktisch Konzeption

Leitprinzipien:

- Zielgruppe: Studierende im Digital Engineering (höheres Bachelorstudium)
- Vorwissen: mathematische Grundlagen sowie erste Programmiererfahrung
- Interaktive Simulationen und eigenständiges Experimentieren statt textbasierter Vermittlung
- angeleitete, schrittweise zurückgenommene Unterstützung
- Vorgehen nach dem ADDIE-Modell




Bloom-Taxonomie, verdichtet auf drei Stufen

Docker & Containerisierung

Architektur

- Webbasierte Single-Page-Application (SPA)
- HTML, CSS und JavaScript
- Bereitstellung über GitHub Pages
- direkt im Browser nutzbar




LERNMODUL

Docker & Containerisierung

In dieser Lerneinheit lernst du, wie reproduzierbare Entwicklungsumgebungen mit Docker aufgebaut werden. Du verstehst die zentralen Konzepte von Images, Containern und Dockerfiles und setzt sie systematisch in einem eigenen Setup um.

Jetzt starten

🕒 ca. 20 Min.




Partielle Differentialgleichungen

- Zwei aufeinander aufbauende Kurse: ein Anfänger- und ein Fortgeschrittenenpfad, per Dialog empfohlen
- Webbasierte Plattform mit HTML, CSS und JavaScript
- Gemeinsames Backend für beide Kurse
- OpenAI-API für den PDE-Piloten
- hier lässt sich nicht mehr rein statisch ausliefern, weil ein Backend mit geheimem API-Key nötig ist



Partielle Differentialgleichungen

- PDE-Pilot: Sechs kontextspezifische Systemprompts



• LERNMODUL

Partielle Differentialgleichungen

beschreiben Prozesse, die sich gleichzeitig in Raum und Zeit verändern, und gehören zu den wichtigsten Werkzeugen der Mathematik.


Hier lernst du PDEs mal anders als in der Vorlesung kennen: nicht über Formelflut, sondern über einen visuellen und schrittweisen Einstieg. So erkennst du, was PDEs sind, warum sie wichtig sind und wofür man sie in der Praxis wirklich braucht.

- Die KI hilft dir, den passenden Einstieg für dein aktuelles Vorwissen zu finden.

PDE-Pilot


Neuronaler Operator

- Szenario: Ingenieurbüro „FieldSolve Engineering“ mit 8 Kapiteln
- Vier Kolleg:innen begleiten den Fortschritt, jede Figur hat eine eigene Rolle
- Gamification: Compute Credits, sechsstufiger Karrierepfad und verschiedene Achievements
- KI-Tutor und dauerhaft begehbaren Räumen



KI-Tutor

- KI-Tutor mit drei Modi: Tutor, Debug-Helfer, Sokrates
- Serverseitiger evaluate-Modus bewertet Freitext-Abschlüsse
- Dreiteiliges Feedback: was stimmt / was fehlt / Vertiefungstipp
- Feste Basiszeile: Rolle im Kontext von FieldSolve Engineering
- Feste Regeln zu Sprache und Antwortlänge (Deutsch, 2–5 Sätze)



FIELDSOLVE ENGINEERING

Neuronale Operatoren

Willkommen bei FieldSolve.

Lern neuronale Operatoren am echten Projektauftrag kennen

8 Kapitel · ca. 90 Minuten

So navigierst du

Drei Bereiche stehen dir zur Verfügung:

LINKS · SIDEBAR

Lernpfad & Team

8 Kapitel werden nacheinander freigeschaltet. Neue Kapitel öffnen sich nach dem Abschluss-Check des vorherigen.

Unter anderem begleiten dich vier Kolleg:innen kontextabhängig durch den Lernpfad.

OBEN · TOOLBAR

Räume

Workstation: Missionen

Simulation Lab: Experimente

Library: Wissensdatenbank

Notebook: Live-Notebook

Trophy Room: Achievements

Archive: Projekt-Akte

UNTEN RECHTS · CHAT


Tutor-Bot

Klick auf den Tutor-Button öffnet ein Chat-Fenster mit **drei Modi:** Tutor, Debug, Sokrates. Der Bot kennt dein aktuelles Kapitel und deinen CC-Stand.

Integration in ein Gesamtsystem

KI-Werkstatt:

- Die 3 Einheiten = erster vollständiger Lernpfad der KI-Werkstatt (HM)
- Pilotprojekt einer hochschulweiten, im Aufbau befindlichen Plattform Teil des Projekts bauwerK!
- Aufbau: Lernpfade aus aufeinander aufbauenden Nuggets, je mit Praxisszenario + eingebauter Evaluation
- kontinuierliche Weiterentwicklung Zugang aktuell nur im Hochschulnetz (Campus-WLAN / EduVPN)



Interaktive KI-Lernnuggets für Studium, Lehre, Forschung und Praxis.

Entdecke geführte Lernpfade, kurze Nuggets und einen KI-Assistenten, der
dich beim Einstieg begleitet.

[Lernpfade entdecken →](#)[Mit Bene Byte starten](#)

Aufbau der Umfrage

Evaluation über einen standardisierten Online-Fragebogen (Google Forms), identisch für alle drei Einheiten, freiwillig und anonym.

Vier Bewertungskategorien (5-stufige Likert-Skala)

1

Gestaltung & Benutzerfreundlichkeit

Übersichtlichkeit, Navigation, Design, Bedienbarkeit

2

Verständlichkeit der Inhalte

Erklärungen, Beispiele, wahrgenommener Lernzuwachs

3

Qualität der interaktiven Elemente

Animationen, Übungen, Motivation, Unterstützung

4

Wahrgenommener Lernerfolg

Interesse, Motivation, Wiederverwendung, Weiterempfehlung

Ergänzend: Vergleich mit klassischen Lernmaterialien, Wunsch nach häufigerem Einsatz und ein offenes Freitextfeld.

Ergebnisse

24

Rückmeldungen
überwiegend Einsteiger:innen

4,58

Ø „Würde weiterempfehlen“
→ höchste Zustimmung

21 / 24

bewerten die Lernmappen als
(deutlich) besser

Mittelwerte je Kategorie & Einheit (1–5)

	Docker	FNO	PDE	Gesamt
Gestaltung & Benutzer- freundlichkeit	4,42	4,54	4,60	4,52
Verständlichkeit der Inhalte	4,42	4,46	4,25	4,38
Interaktive Elemente	4,24	4,24	4,65	4,38
Lernerfolg	3,98	4,14	4,35	4,15

Einziger Freitext: „die Wassersimulation war sehr cool“ (PDE).

Einordnung & Limitationen

Was die Ergebnisse stützen

- Interaktive Format wird klar gegenüber klassischen Materialien bevorzugt
- Gestaltung & Bedienbarkeit über alle drei Einheiten stabil
- Andeutung: Interaktivität senkt die Einstiegshürde bei abstrakten Themen

Grenzen der Aussagekraft

- Kleine, freiwillige Stichprobe ($n = 24$)
- Ausschläge gehen auf 2 Einzelstimmen zurück
- Nur wahrgenommener Lernerfolg, kein Wissenstest

Fazit

Ein abstraktes Thema wird über einen aufeinander aufbauenden Lernpfad zugänglich.

Mit den drei Einheiten liegt der erste vollständige Lernpfad der KI-Werkstatt vor.

Ausblick

- Plattform-Ausbau (3 → N) + Logging/Datenschutzkonzept
- Agenten-Pipeline, adaptive Pfade
- Qualitätsvergleich KI vs. Manuell → A/B-Test-Setup

HOCHSCHULE MÜNCHEN · FAKULTÄT MUC.DAI

BACHELORARBEIT · KOLLOQUIUM

Vielen Dank für Ihre Aufmerksamkeit!

Miray Kurt

Studiengang Digital Engineering


Backup

Übersicht der Lerneinheiten

	Docker & Containerisierung	Partielle Differentialgleichungen	Neuronale Operatoren
Rolle im Lernpfad	Technisches Fundament	Fachlicher Kern	Verbindung und Anwendung
Zentrale Fragestellung	Wie wird eine reproduzierbare Entwicklungsumgebung erstellt?	Wie lassen sich physikalische Prozesse mathematisch beschreiben?	Wie können PDEs durch KI effizient gelöst werden?
Lernunterstützung	Geführte Tutorials	Interaktive Lernbegleitung	Individuelle Unterstützung und Wissensvertiefung

Vorgehen

- Vorgehen nach dem ADDIE-Modell
- Iterative Variante statt strikt linearer Abfolge
- Technischer Aufwand wächst mit inhaltlicher Komplexität



<https://www.sessionlab.com/blog/addie-model-instructional-design/>

Aufbau des Trainings

Ein Operator ist keine feste Abbildung zwischen Zahlenvektoren, sondern bildet eine ganze Funktion auf eine Funktion ab

Vier PDEBench-Datensätze mit steigendem Schwierigkeitsgrad

1D-Advektion ($\beta = 0,2$)

1024 *glatt, "leicht"*

1D-Advektion ($\beta = 4,0$)

1024 *schärfer, schwieriger*

2D-CFD Rand

128^2 *4 Kanäle, anspruchsvoller*

2D-CFD Turbulent

512^2 *4 Kanäle, anspruchsvoll*

Konfiguration

- 4 Fourier-Schichten, 64 verborgene Kanäle, GELU
- AdamW, Lernrate $1 \cdot 10^{-3}$, Weight-Decay $1 \cdot 10^{-4}$
- 100 Epochen
- Trainingsziel: H1-Verlust; Split 80/10/10
- 4 Datensätze $\times$ 3 Modenzahlen = 12 Läufe
- Bewertung: relativer L2-Fehler
- Docker-Image (PyTorch 2.5.1, CUDA 12.4)

Ergebnis des Trainings

